

INFRAESTRUCTURA
HARDWARE

Compute	AMD Ryzen 7 7700X (8C/16T, up to 5.4GHz)
Memoria	32 GB DDR5 RAM
VRAM	NVIDIA RTX 4060 Ti
GPU	16 GB GDDR6 dedicados
OS/Host	Pop!_OS (Linux) Kernel 7.0

ORQUESTACIÓN Y CORE

Motor Containers	Docker / Docker Compose v2
Redes	Aislamiento bridge externo <code>ai-stack-default</code>
Volúmenes	Persistencia estricta para índices vectoriales y UI
Aceleración	NVIDIA Container Toolkit (Passthrough GPU nativo)

MÉTRICAS DE OPERACIÓN
REAL

14.2 GB USO VRAM ACTIVO	11 MODELOS EN CATÁLOGO	16K CONTEXTO ACTIVO
----------------------------	---------------------------	------------------------

PIPELINE DE DATOS AVANZADO (RAG)

Implementación completa de un flujo **Retrieval-Augmented Generation** local con total control y privacidad de la información:

1. Ingesta y Fragmentación

Estrategia de Chunking optimizada a **1024 tokens** con un Overlap estricto de **200 tokens** para evitar pérdida de contexto perimetral.

2. Indexación Vectorial

Generación de embeddings en tiempo real y almacenamiento estructurado en colecciones dedicadas en **Qdrant** (ej. `open-webui_files`: 1,732 puntos).

3. Recuperación Avanzada

Búsqueda por similitud configurada en **Top_K = 10** documentos concurrentes con un umbral estricto de relevancia de corte fijado en **0.2**.

4. Inferencia Segura

Enriquecimiento dinámico del Prompt e inferencia local en GPU a una temperatura de **0.7** garantizando privacidad absoluta (cero fugas de datos).

OBSERVABILIDAD Y MONITOREO

Despliegue de un demonio propietario de telemetría (`monitor_server2.py` en puerto 8765) que consolida métricas en tiempo real de temperatura de GPU (48°C base), consumo de energía (16W idle/load dinámico), hilos de CPU y control de logs en caliente.

SERVICIOS Y ARQUITECTURA DE SOFTWARE

Arquitectura desacoplada basada en Microservicios Independientes:

- Open WebUI (Puerto 3000):** Gateway de usuario integrado, gestión de identidades securizada (`ENABLE_SIGNUP=false`), e interfaz avanzada de ingeniería de prompts.
- Ollama API (Puerto 11434):** Orquestador nativo para inferencia local de pesos LLM, optimizando la asignación de capas a la GPU.
- Qdrant DB (Puerto 6333/6334):** Motor de búsqueda vectorial de alta velocidad encargado de almacenar y recuperar representaciones numéricas (*embeddings*).
- SearXNG (Puerto 8888):** Metamotor de búsqueda web anónimo integrado al backend para inyección de datos en tiempo real al modelo.
- Docling GUI & Watcher:** Engine integrado para el parseo avanzado y chunking optimizado de archivos documentales complejos a Markdown limpio.

GESTIÓN DE MODELOS Y CUANTIZACIÓN

`gemma-4-12b-it-q8` `qwen2.5:32b` `deepseek-r1:14b`
`qwen2.5-coder:14b` `qwen2.5vl (Vision)` `aya-expanse:8b`

Especialización en entornos de ejecución mixtos mediante importación nativa de formatos `GGUF` (de LM Studio a Ollama). Modelos embebidos configurados con `bge-m3` y `nomie-embed-text` para la generación precisa de vectores densos.

COMPETENCIAS CLAVE DEMOSTRADAS

DevOps & Virtualización: Redes Docker avanzadas, persistencia y control de hardware.

AI Engineering: Despliegue de LLMs locales, cuantización, bases de datos vectoriales (Qdrant).

Data & Privacy: Pipelines de datos (RAG) privados enfocados en cumplimiento (GDPR/Compliance).